



UNIVERSITÀ
POLITECNICA
DELLE MARCHE

FACOLTÀ DI INGEGNERIA
CORSO DI LAUREA IN INGEGNERIA INFORMATICA E DELL'AUTOMAZIONE

Visualsync

Autori:

Davide Acciarri
Giacomo Marcucci

Tutor:

Rocco Pietrini

Anno Accademico 2025-2026

Indice

1	Introduzione	1
2	Stato dell'arte	3
3	Strumenti e architetture	5
3.1	Struttura Dataset	5
3.2	Modelli	5
3.2.1	GPT	5
3.2.2	Grounded-SAM	5
3.2.3	DEVA	5
3.2.4	CoTracker3	5
3.2.5	Mast3R	5
3.2.6	VGGT	5
3.3	Le tre fasi di visualsyntax	5
3.3.1	Fase 0	5
3.3.2	Fase 1	5
3.3.3	Fase 2	5
4	Miglioramenti e ottimizzazioni architetture	7
5	Risultati finali	9
6	Conclusioni	11

Elenco delle figure

Elenco delle tabelle

Capitolo 1

Introduzione

Con la diffusione di smartphone e dispositivi portatili, è comune che uno stesso evento dinamico, come una partita di calcio, un concerto o una festa in famiglia, venga ripreso da più angolazioni da diverse persone. Tuttavia, allineare questi flussi video per scopi di ricostruzione 4D o editing professionale rimane una sfida complessa a causa della natura frammentaria e casuale delle riprese. Per la sincronizzazione temporale di video multi-camera acquisiti in modo indipendente e non coordinato, è stato progettato un framework di ottimizzazione, VisualSync. I metodi di sincronizzazione esistenti si basano su ambienti controllati, annotazioni manuali, pattern specifici come human pose, segnali audio, o costosi setup hardware come dispositivi time-coded, nessuno dei quali è disponibile in video registrati casualmente. Un altro aspetto da dover affrontare è che i video sono spesso "unposed", ovvero non si hanno informazioni a priori riguardanti la posizione spaziale, l'orientamento o i parametri intrinseci delle telecamere al momento della ripresa. Inoltre, costruire un sistema pratico e robusto che funzioni su video reali è impegnativo, in quanto gli oggetti dinamici sono a priori sconosciuti e generalmente piccoli e sfocati, e non tutte le viste possono avere sovrapposizione. Il problema parte da un insieme di N video asincroni che riprendono la stessa scena dinamica da diversi punti di vista e l'obiettivo è sincronizzarli e recuperare un timestamp allineato globalmente. Formalmente, si cerca di stimare un offset temporale per ogni video da applicare al suo tempo di clock originale fuori sincronizzazione. Dopo la sincronizzazione, i frame che condividono lo stesso tempo di clock corrisponderanno allo stesso momento in tutti i video. È possibile vedere la sincronizzazione globale come un problema di minimizzazione dell'energia ovvero, miriamo a trovare gli offset che allineino meglio tutte le coppie di video minimizzando il loro errore di sincronizzazione pairwise. La minimizzazione dell'energia pone tre sfide: il problema di ottimizzazione è altamente non convesso, la formulazione è a tempo continuo, ma le osservazioni arrivano a tempi di frame discreti e che negli scenari reali, è difficile associare traiettorie dense tra fotocamere con punti di vista molto diversi e stimare pose accurate per fotocamere in movimento. Per scrivere questa relazione abbiamo usato come riferimento le seguenti fonti: [1], [2], [3], [4], [5], [6], [7], [8]

Capitolo 2

Stato dell'arte

Lo stato dell'arte relativo alla sincronizzazione e alla ricostruzione di scene dinamiche multi-camera ha subito una trasformazione radicale grazie all'avvento dei modelli di fondazione visiva e di nuove tecniche di ottimizzazione geometrica. La sincronizzazione video è stata esplorata da più prospettive. I metodi basati sulla geometria, come quelli introdotti da Albl e da Li, stimano offset temporali usando la geometria epipolare, ma tipicamente assumono scene statiche o punti di vista fissi. Gli approcci human-centric usano la pose umana come segnale di sincronizzazione, ma sono limitati dall'accuratezza della stima della pose, dal numero di persone nella scena, e faticano in scenari senza attività umana prominente. Gli approcci basati sull'audio usano indizi audio per la sincronizzazione, ma funzionano solo in ambienti silenziosi e non sono generalmente applicabili a contesti reali in cui l'audio è rumoroso o non disponibile. I metodi basati sull'apprendimento come Sync-NeRF, ottimizzano congiuntamente pose e offset temporali, ma spesso sono vincolati ad ambienti o tipi di oggetti specifici. VisualSync supera questi limiti sfruttando modelli visivi pre-addestrati e inquadrando la sincronizzazione come un problema di ottimizzazione basato sull'epipolarità. Ragionando congiuntamente su strutture statiche e movimenti dinamici in primo piano, è stata definita una soluzione generalizzabile per allineare video asincroni e non posizionati in scenari reali complessi. Per la Multi-View Structure-from-Motion ci sono tecniche Structure-from-Motion (SfM), come COLMAP, che hanno significativamente avanzato le pipeline di ricostruzione 3D producendo pose accurate delle fotocamere da immagini e video multi-vista. Modelli più recenti come HLOC, Hierarchical-Localization, e VGGT, Visual Geometry Grounded Transformer, si basano su questi progressi usando feature basate sull'apprendimento e transformer per gestire il matching su larga scala e la stima della pose. Sebbene questi metodi raggiungano forti prestazioni nella stima della geometria delle fotocamere, sono carenti nella sincronizzazione di scene dinamiche, poiché si basano principalmente su indizi visivi statici. VisualSync decompone esplicitamente la scena in componenti statiche e dinamiche, sfruttando gli indizi statici per la stima della pose e gli indizi dinamici dagli oggetti in movimento per eseguire una robusta sincronizzazione temporale tra viste. Per il tracking e le corrispondenze ci sono modelli come CoTracker tracciano punti densamente nel tempo, offrendo una forte coerenza temporale. Tuttavia, non modellano le corrispondenze spaziali tra

punti di vista diversi. D'altro canto, MAST3R si concentra sul matching spaziale e la ricostruzione stereo, fornendo corrispondenze cross-view dense, ma non gestisce la dinamica temporale, specialmente in scene in movimento. VisualSync colma questa lacuna costruendo corrispondenze cross-view spazio-temporali, integrando sia il tracking temporale che il matching spaziale per abilitare una sincronizzazione accurata in contesti video multi-vista dinamici. Il framework Uni4D ha come obiettivo quello di unificare diversi modelli di fondazione pre-addestrati per ricostruire scene 4D da un singolo video casuale. Uni4D eccelle nella ricostruzione della geometria dinamica e nella stima della posa della telecamera ma, quando viene utilizzato come baseline per la sincronizzazione multi-video, in presenza di oggetti dinamici, piccoli o distanti, presenta delle incertezze. VisualSync adotta esplicitamente la pipeline di segmentazione degli oggetti dinamici introdotta da Uni4D, infatti utilizza la logica di Uni4D per identificare cosa si muove nella scena e separarlo dallo sfondo statico. Uni4D si basa su Recognize Anything e un filtraggio tramite LLM, invece, VisualSync, utilizza direttamente GPT-4o per identificare le classi dinamiche, mantenendo però la struttura di propagazione temporale tipica di Uni4D. La segmentazione si è spostata dai modelli addestrati su classi specifiche come persone o veicoli, a sistemi universali. Il modello SAM 2, Segment Anything Model 2, è l'attuale punto di riferimento ed è un modello fondamentale per la risoluzione del problema della segmentazione visiva guidata da prompt in immagini e video tramite una memoria di streaming che permette di mantenere la coerenza temporale anche in sequenze lunghe e complesse. Framework come DEVA hanno ulteriormente raffinato questo approccio, introducendo un sistema di propagazione bidirezionale che de-normalizza gli errori dei modelli a frame singolo.

Capitolo 3

Strumenti e architetture

3.1 Struttura Dataset

3.2 Modelli

3.2.1 GPT

3.2.2 Grounded-SAM

3.2.3 DEVA

3.2.4 CoTracker3

3.2.5 Mast3R

3.2.6 VGGT

3.3 Le tre fasi di visualsync

3.3.1 Fase 0

3.3.2 Fase 1

3.3.3 Fase 2

Capitolo 4

Miglioramenti e ottimizzazioni architettureali

Capitolo 5

Risultati finali

Capitolo 6

Conclusioni

Bibliografia

- [1] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment Anything in Images and Videos.
- [2] Shaowei Liu, David Yifan Yao, Saurabh Gupta, and Shenlong Wang. Visual Sync: Multi-Camera Synchronization via Cross-View Object Motion, December 2025.
- [3] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Alexander Schwing, and Joon-Young Lee. Tracking Anything with Decoupled Video Segmentation, September 2023.
- [4] David Yifan Yao, Albert J. Zhai, and Shenlong Wang. Uni4D: Unifying Visual Foundation Models for 4D Modeling from a Single Video, March 2025.
- [5] Vincent Leroy, Yohann Cabon, and Jérôme Revaud. Grounding Image Matching in 3D with MAST3R, June 2024.
- [6] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual Geometry Grounded Transformer.
- [7] Nikita Karaev, Iurii Makarov, Jianyuan Wang, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker3: Simpler and Better Point Tracking by Pseudo-Labeling Real Videos, October 2024.
- [8] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. CoTracker: It is Better to Track Together, October 2024.