



UNIVERSITÀ
POLITECNICA
DELLE MARCHE

FACOLTÀ DI INGEGNERIA
CORSO DI LAUREA IN INGEGNERIA INFORMATICA E DELL'AUTOMAZIONE

Visualsync

Autori:
Davide Acciarri
Giacomo Marcucci

Tutor:
Rocco Pietrini

Anno Accademico 2025-2026

Indice

1	Capitolo 1	1
2	Capitolo 2	3

Elenco delle figure

Elenco delle tabelle

Capitolo 1

Capitolo 1

Con la diffusione di smartphone e dispositivi portatili, è comune che uno stesso evento dinamico, come una partita di calcio, un concerto o una festa in famiglia, venga ripreso da più angolazioni da diverse persone. Tuttavia, allineare questi flussi video per scopi di ricostruzione 4D o editing professionale rimane una sfida complessa a causa della natura frammentaria e casuale delle riprese. Per la sincronizzazione temporale di video multi-camera acquisiti in modo indipendente e non coordinato, è stato progettato un framework di ottimizzazione, VisualSync. I metodi di sincronizzazione esistenti si basano su ambienti controllati, annotazioni manuali, pattern specifici come human pose, segnali audio, o costosi setup hardware come dispositivi time-coded, nessuno dei quali è disponibile in video registrati casualmente. Un altro aspetto da dover affrontare è che i video sono spesso "unposed", ovvero non si hanno informazioni a priori riguardanti la posizione spaziale, l'orientamento o i parametri intrinseci delle telecamere al momento della ripresa. Inoltre, costruire un sistema pratico e robusto che funzioni su video reali è impegnativo, in quanto gli oggetti dinamici sono a priori sconosciuti e generalmente piccoli e sfocati, e non tutte le viste possono avere sovrapposizione. Il problema parte da un insieme di N video asincroni che riprendono la stessa scena dinamica da diversi punti di vista e l'obiettivo è sincronizzarli e recuperare un timestamp allineato globalmente. Formalmente, si cerca di stimare un offset temporale per ogni video da applicare al suo tempo di clock originale fuori sincronizzazione. Dopo la sincronizzazione, i frame che condividono lo stesso tempo di clock corrisponderanno allo stesso momento in tutti i video. È possibile vedere la sincronizzazione globale come un problema di minimizzazione dell'energia ovvero, miriamo a trovare gli offset che allineino meglio tutte le coppie di video minimizzando il loro errore di sincronizzazione pairwise. La minimizzazione dell'energia pone tre sfide: il problema di ottimizzazione è altamente non convesso, la formulazione è a tempo continuo, ma le osservazioni arrivano a tempi di frame discreti e che negli scenari reali, è difficile associare traiettorie dense tra fotocamere con punti di vista molto diversi e stimare pose accurate per fotocamere in movimento.

Capitolo 2

Capitolo 2

Lo stato dell'arte relativo alla sincronizzazione e alla ricostruzione di scene dinamiche multi-camera ha subito una trasformazione radicale grazie all'avvento dei modelli di fondazione visiva e di nuove tecniche di ottimizzazione geometrica. Tradizionalmente, la sincronizzazione tra diverse telecamere dipendeva da hardware costosi, segnali audio specifici o riferimenti visivi intenzionali. In contesti non controllati, i metodi si sono evoluti verso l'uso della geometria epipolare, ma spesso limitandosi a scene statiche o a telecamere fisse. Recentemente, modelli come Sync-NeRF hanno tentato di risolvere il problema tramite l'ottimizzazione di campi di radianza dinamici, ma presentano difficoltà in presenza di grandi offset temporali o scene complesse a causa della mancanza di forti prior geometrici. VisualSync si posiziona all'avanguardia superando questi limiti, utilizzando l'Errore di Sampson applicato a tracce di punti densi per ottenere una precisione millimetrica. Il settore del SfM, Structure-from-Motion, è passato dai metodi incrementali classici come COLMAP, basati su feature sparse e rigide, a modelli basati su trasformatori. Il modello VGGT, Visual Geometry Grounded Transformer, rappresenta lo stato dell'arte attuale, essendo in grado di stimare congiuntamente pose, intrinseche e mappe di profondità in modo feed-forward in meno di un secondo, superando in velocità e precisione i complessi sistemi di ottimizzazione post-processing precedenti. Un altro riferimento chiave è MAST3R, che ha introdotto la capacità di stabilire corrispondenze dense e robuste tra viste con angolazioni estreme. Il paradigma del tracciamento è evoluto dal tracciamento indipendente di singoli punti verso il tracciamento congiunto. CoTracker e il suo successore CoTracker3 rappresentano l'eccellenza in questo campo, sfruttando meccanismi di attenzione per seguire decine di migliaia di punti simultaneamente, garantendo robustezza estrema contro le occlusioni e la scomparsa temporanea degli oggetti dal campo visivo. L'uso di pseudo-labeling su video reali ha permesso a questi modelli di superare le prestazioni ottenute con soli dati sintetici. La segmentazione si è spostata dai modelli addestrati su classi specifiche come persone o veicoli, a sistemi universali. SAM 2, Segment Anything Model 2, è l'attuale punto di riferimento, estendendo la capacità di segmentazione promptabile dalle immagini ai video tramite una memoria di streaming che permette di mantenere la coerenza temporale anche in sequenze lunghe e complesse. Framework come DEVA hanno ulteriormente raffinato questo approccio, introducendo un sistema di propagazione bidirezionale

che de-normalizza gli errori dei modelli a frame singolo.

Capitolo 3

Capitolo 4

Capitolo 5

Capitolo 6

